

Guía Definitiva: El Ciclo de Aprendizaje PPO bajo el Capó

(Referencia para el Proyecto de Portafolios DRL con SB3)

Esta guía detalla el flujo exacto de datos y transformaciones matemáticas que ocurren dentro de la librería `stable_baselines3` (SB3) al entrenar un agente PPO para la gestión de portafolios (SPX y CMC200), siguiendo los lineamientos de la Metodología Matemática.

FASE 1: RECOLECCIÓN DE EXPERIENCIA (El Rollout)

Durante esta fase, la red neuronal (Política) está **congelada** en modo de solo lectura. El agente interactúa con el mercado para acumular datos en una memoria temporal.

Paso 1: La Observación (Input de la Red)

Al inicio de cada periodo t , el entorno (`PortfolioEnv`) ensambla el **Vector de Estado (o_t)** y se lo entrega a la red neuronal del Actor. Este vector contiene:

- **Variables Internas:** El capital actual (x_t), los pesos del periodo anterior (w_{t-1}) y el progreso del tiempo normalizado (t/T).
- **Variables Exógenas:** Las *features* entregadas por tu `DataHandler` (medias, varianzas y covarianzas normalizadas).

Paso 2: La Decisión del Actor (Política Estocástica)

El vector de estado pasa a través de las capas ocultas (Feedforward) de la red neuronal (MLP) del **Actor**.

- **Lo que sale de la red:** La red **NO** arroja los porcentajes a invertir. En su lugar, arroja los parámetros para construir una campana de Gauss (Distribución Normal Multivariada) para cada activo: una Media (μ) y una Desviación Estándar (σ).
- **El Muestreo (Tirar los dados):** SB3 toma esa campana de Gauss y elige un número al azar dentro de ella. Esto nos da un vector de acciones continuas libres $\tilde{a}_t$. La amplitud de esta campana (la estocasticidad) es lo que permite que el agente "explore" y tome decisiones ligeramente distintas aunque vea el mismo estado.
- **La Proyección:** Tu entorno toma esos números libres $\tilde{a}_t$ y les aplica la fórmula matemática de proyección (Softmax o división por la suma) para convertirlos en los **pesos finales válidos** ($w_{i,t}$), garantizando que sean positivos y sumen 1 (100%).

Paso 3: Interacción y Consecuencias (Step)

Con los pesos $w_{i,t}$ definidos, el entorno avanza un paso de tiempo:

1. Observa el retorno real del mercado en esa semana.
2. Calcula la rotación del portafolio para descontar los **costos de transacción** monetarios (c_{SPX}, c_{CMC}).
3. Calcula el nuevo capital resultante (x_{t+1}).
4. Genera la **Recompensa** (r_t) para evaluar qué tan buena fue esa decisión.

Paso 4: Bucle de Episodios hasta llenar el Rollout

El agente guarda esta experiencia (s_t, a_t, r_t, s_{t+1}) en su memoria temporal (buffer) y repite los pasos 1 a 3.

- **El Episodio (114 pasos):** Cuando el agente llega a la semana 114 de tus datos de entrenamiento, se le acaba el tiempo. El entorno marca `done = True`, el capital se reinicia a \$10,000, y el agente vuelve a la semana 1. Esto es 1 Episodio.
- **El Rollout (Ej: 2048 pasos):** El agente repite este ciclo de vida una y otra vez (jugando aproximadamente 18 episodios completos) hasta juntar 2048 experiencias en su memoria temporal.

FASE 2: EVALUACIÓN Y APRENDIZAJE (La Actualización)

Una vez que el buffer del Rollout llega a sus 2048 pasos, la simulación **se pausa**. Comienza el proceso de aprendizaje matemático.

Paso 5: La Evaluación del Crítico y la Ventaja

Entra en juego la segunda red neuronal: el **Crítico** (Función de Valor). El Crítico mira los 2048 estados por los que pasó el Actor y hace su predicción: $V(s_t)$. Luego, se calcula la **Ventaja** ($\hat{A}_t$):

$$\text{Ventaja} = (\text{Lo que realmente ganamos en la simulación}) - (\text{Lo que el Crítico predijo que ganaríamos})$$

Si la Ventaja es positiva, la acción fue inesperadamente buena. Si es negativa, fue mala.

Paso 6: Backpropagation y la Función Loss (El Clímax)

PPO agrupa esos 2048 datos en lotes pequeños (mini-batches) y los pasa varias veces (epochs) por un Optimizador (usualmente Adam). El objetivo del optimizador es minimizar una **Función Loss Combinada** compuesta de 3 partes:

1. **Loss de Política (Actualiza al Actor):** Multiplica las probabilidades de las acciones por la Ventaja ($\hat{A}_t$). Usa una regla matemática llamada **Clipping** (recorte) que impide que la red neuronal cambie sus pesos bruscamente (máximo un 20%). Esto garantiza un aprendizaje estable y prudente.

2. **Loss de Valor (Actualiza al Crítico):** Usa el Error Cuadrático Medio. Ajusta los pesos de la red del Crítico para que sus predicciones $V(s_t)$ se acerquen más a la realidad, volviéndolo un mejor "supervisor" para el próximo ciclo.
3. **Bono de Entropía:** Recompensa matemáticamente a la red del Actor si su campana de Gauss se mantiene ancha. Esto contrarresta la tendencia de la red a volverse predecible muy rápido, forzándola a seguir explorando.

Paso 7: Reinicio del Ciclo

El optimizador aplica el algoritmo de *Backpropagation*, ajustando físicamente los números (pesos y sesgos) dentro de las neuronas de ambas redes. **La Política ha cambiado oficialmente.** Finalmente, SB3 **borra completamente** los 2048 pasos de la memoria temporal. El agente vuelve al Paso 1 con una red neuronal ligeramente más inteligente, listo para recolectar otros 2048 pasos con su nueva política. Este mega-ciclo se repite hasta completar el `total_timesteps` de tu entrenamiento.