



CONSTRUCCIÓN DE PORTAFOLIOS DE INVERSIÓN CON DEEP REINFORCEMENT LEARNING

RODRIGO VALENZUELA T.

MEMORIA PARA OPTAR AL TÍTULO DE
INGENIERO CIVIL INDUSTRIAL

PROFESOR GUÍA: JUAN PÉREZ RETAMALES
PROFESOR CO-GUÍA: PAOLO LATORRE

SANTIAGO, SEPTIEMBRE DE 2026

Agradecimientos

Índice general

Resumen	5
1. Introducción	6
1.1. Contexto y Motivación	6
1.2. Definición del Problema	6
1.3. Objetivos	7
1.3.1. Objetivo General	7
1.3.2. Objetivos Específicos	7
2. Marco Teórico	9
2.1. Teoría de Portafolio Clásica	9
2.1.1. Modelo de Markowitz y Optimización Media-Varianza	9
2.1.2. Ratios de Desempeño: Sharpe y Sortino	10
2.1.3. Entropía de Shannon y Diversificación	10
2.2. Deep Reinforcement Learning (DRL)	10
2.2.1. Proceso de Decisión de Markov (MDP) y Ecuación de Bellman	10
2.3. Algoritmos PPO y SAC	11
2.3.1. Proximal Policy Optimization (PPO)	11
2.3.2. Soft Actor-Critic (SAC)	11
2.4. Regímenes de Mercado y Modelos Ocultos	12
3. Metodología y Formulación del Modelo	13
3.1. Datos y Preprocesamiento	13
3.2. Formulación del MDP/POMDP	14
3.2.1. Espacio de Observación (S)	14
3.2.2. Espacio de Acción (A)	14
3.2.3. Función de Recompensa (R)	14
3.3. Diseño del Entorno (Gym)	15
3.4. Arquitectura y Configuración del Agente	15

Índice de figuras

Índice de tablas

Resumen

Capítulo 1

Introducción

1.1. Contexto y Motivación

En la actualidad, los mercados financieros se caracterizan por una creciente complejidad y un dinamismo continuo, lo que dificulta significativamente la labor de toma de decisiones en el ámbito de las inversiones. Tradicionalmente, la construcción y gestión de portafolios de inversión se ha basado en fundamentos analíticos clásicos, como la Teoría Moderna de Portafolios (MPT) propuesta por Harry Markowitz. Si bien estos modelos han cimentado las bases para equilibrar el retorno esperado y el riesgo, suelen depender de supuestos restrictivos sobre la distribución y estacionariedad de los retornos financieros.

A medida que la disponibilidad de datos a gran escala ha aumentado y el poder de cómputo se ha expandido, ha surgido una necesidad imperante de adoptar herramientas de optimización automatizadas y más sofisticadas. Los regímenes de mercado cambian abruptamente entre periodos de crecimiento sostenido (estados *Bull*) y etapas de recesión o alta volatilidad (estados *Bear*). Esta variabilidad demanda estrategias de asignación de capital que sean no solo eficientes, sino también altamente adaptables frente a condiciones de observabilidad parcial de los estados del mercado.

Bajo este contexto, el Aprendizaje por Refuerzo Profundo (Deep Reinforcement Learning o DRL) emerge como una solución vanguardista. A diferencia de los enfoques estáticos o de un solo periodo, el DRL permite modelar el mercado como un entorno estocástico donde un agente aprende estrategias dinámicas, interactuando secuencialmente, tomando acciones y recibiendo recompensas basadas en el desempeño del portafolio.

1.2. Definición del Problema

La formulación tradicional del problema de asignación de activos a menudo se ha abordado mediante modelos de optimización deterministas. En muchos estudios y aplicaciones industriales, se emplea la plataforma GAMS (General Algebraic Modeling Sys-

tem) utilizando enfoques de horizonte rodante (*rolling horizon*) o paradigmas *Smart-Predict-then-Optimize* (SPO).

Sin embargo, estos modelos convencionales presentan limitaciones considerables. En primer lugar, la resolución de problemas de optimización deterministas periodo a periodo bajo un horizonte móvil puede volverse computacionalmente costosa y reactiva en exceso. En segundo lugar, y más importante, la naturaleza determinista de estos esquemas tradicionales restringe su capacidad para anticipar y adaptarse proactivamente a las transiciones ocultas en los regímenes de mercado. Al asumir parámetros estáticos para periodos futuros inmediatos, el modelo GAMS es propenso a subestimar el riesgo en caídas abruptas de mercado, o a generar altos costos de transacción debidos a rebalanceos excesivos no contemplados en una estrategia a largo plazo.

Por consiguiente, el problema radica en diseñar una política de inversión que supere las deficiencias de los enfoques deterministas miopes. Se requiere un modelo capaz de aprender patrones subyacentes complejos y de gestionar activamente el compromiso o *trade-off* entre la maximización de retornos, la mitigación del riesgo y el impacto directo de los costos de transacción, todo esto dentro de un mercado parcialmente observable que transita entre ciclos *Bear* y *Bull*.

1.3. Objetivos

1.3.1. Objetivo General

Desarrollar, implementar y comparar políticas dinámicas de asignación de portafolio mediante algoritmos de Deep Reinforcement Learning, específicamente Proximal Policy Optimization (PPO) y Soft Actor-Critic (SAC), con el propósito de maximizar el retorno esperado del portafolio ajustado por el riesgo y los costos de transacción, en presencia de regímenes de mercado parcialmente observables.

1.3.2. Objetivos Específicos

Para alcanzar el objetivo general propuesto, se definen los siguientes objetivos específicos:

1. Formular formalmente el problema de gestión de portafolios como un Proceso de Decisión de Markov Parcialmente Observable (POMDP), definiendo rigurosamente el espacio de estados, acciones, transición y función de recompensa.
2. Implementar un entorno de simulación financiero estandarizado (Gym) que integre series de tiempo reales, modelos probabilísticos para señales de mercado y lógica de rebalanceo de activos considerando fricciones.

3. Desarrollar y entrenar agentes mediante PPO y SAC incorporando arquitecturas de redes neuronales recurrentes para el manejo efectivo de la observabilidad parcial de los regímenes *Bear* y *Bull*.
4. Evaluar y comparar empíricamente el desempeño fuera de muestra de los agentes DRL contra los resultados obtenidos por benchmarks convencionales, tales como la solución determinista de GAMS en horizonte móvil y la estrategia *Buy-and-Hold*.
5. Realizar estudios de sensibilidad sobre los hiperparámetros clave y factores económicos, como la aversión al riesgo y los costos de transacción, para comprobar la robustez de las políticas aprendidas.

Capítulo 2

Marco Teórico

En el presente capítulo se exponen los fundamentos conceptuales y matemáticos sobre los cuales se desarrolla la metodología de esta memoria. Inicialmente, se revisa la Teoría Clásica de Portafolios, abordando los enfoques tradicionales de optimización de inversiones. A continuación, se introducen los conceptos centrales del Aprendizaje por Refuerzo Profundo (Deep Reinforcement Learning, DRL), los Procesos de Decisión de Markov (MDP) y los algoritmos específicos de frontera utilizados (PPO y SAC). Finalmente, se define el contexto de los regímenes de mercado y su modelación estadística a través de Modelos Ocultos de Markov (HMM).

2.1. Teoría de Portafolio Clásica

2.1.1. Modelo de Markowitz y Optimización Media-Varianza

La Teoría Moderna de Portafolios (Modern Portfolio Theory o MPT), propuesta por Markowitz (1952), revolucionó la forma en que los inversionistas construyen sus carteras. El modelo se fundamenta en la premisa de que un inversionista racional es averso al riesgo; es decir, frente a dos carteras con el mismo retorno esperado, preferirá aquella con menor nivel de riesgo.

Matemáticamente, el retorno esperado de un portafolio se define como la suma ponderada de los retornos esperados de los activos individuales, mientras que el riesgo se cuantifica mediante la varianza (o desviación estándar) de los retornos del portafolio. Este riesgo no solo depende de la varianza de cada activo, sino fundamentalmente de las covarianzas entre ellos, lo que introduce el principio de la diversificación. El problema de optimización busca minimizar la varianza del portafolio dado un retorno objetivo, o equivalentemente, maximizar el retorno esperado para un nivel máximo de riesgo tolerable. Una limitación inherente de este modelo es su tendencia a generar “corner solutions”, es decir, carteras altamente concentradas en pocos activos y sumamente sensibles a pequeños errores en la estimación de las medias y covarianzas.

2.1.2. Ratios de Desempeño: Sharpe y Sortino

Para evaluar la calidad de un portafolio más allá de su simple retorno absoluto, se introdujeron métricas que penalizan el retorno en función del riesgo asumido. El **Ratio de Sharpe** (Sharpe, 1966) mide el exceso de retorno (o prima de riesgo) obtenido por unidad de volatilidad (desviación estándar total). Su objetivo es identificar portafolios que maximicen esta relación. Sin embargo, este ratio no discrimina entre desviaciones positivas y negativas, penalizando equivocadamente los retornos inesperadamente altos.

Para subsanar esta deficiencia, surge el **Ratio de Sortino** (Sortino and Price, 1994), el cual reemplaza la desviación estándar total del denominador por la desviación a la baja (*downside deviation*). De este modo, solo se penaliza la volatilidad que genera pérdidas respecto a un retorno mínimo aceptable, permitiendo a los inversores beneficiarse de la volatilidad positiva sin ser penalizados por ella.

2.1.3. Entropía de Shannon y Diversificación

Una alternativa complementaria al modelo de Markowitz es la inclusión de la **Entropía de Shannon** (Shannon, 1948) en la función objetivo. La entropía mide el grado de dispersión en la distribución de las ponderaciones del portafolio. Maximizar la entropía favorece la diversificación, evitando la hiper-concentración. El modelo Ingenuo (*Naive* o *Equally-Weighted*), que asigna la misma ponderación a todos los activos ($1/N$), representa el límite superior de máxima entropía, operando bajo el principio de total ignorancia sobre el desempeño futuro de los activos.

2.2. Deep Reinforcement Learning (DRL)

El Aprendizaje por Refuerzo (Reinforcement Learning o RL) es un paradigma del aprendizaje automático donde un agente aprende a tomar decisiones óptimas interactuando continuamente con un entorno estocástico (Sutton and Barto, 2018). A diferencia del aprendizaje supervisado, el agente no recibe ejemplos etiquetados sobre qué acciones tomar, sino que debe descubrir las acciones más rentables mediante un esquema de exploración y explotación, guiado por una señal escalar denominada recompensa.

2.2.1. Proceso de Decisión de Markov (MDP) y Ecuación de Bellman

El marco matemático subyacente para modelar estos problemas secuenciales es el Proceso de Decisión de Markov (MDP) (Bellman, 1957). Un MDP se define formalmente por la tupla $\langle S, A, P, R, \gamma \rangle$:

- S : Espacio de estados que contiene la información observable del entorno.

- A : Espacio de acciones posibles a tomar por el agente.
- $P(s'|s, a)$: Dinámica de transición, que representa la probabilidad de transitar al estado s' al ejecutar la acción a desde el estado s .
- $R(s, a)$: Función de recompensa inmediata recibida tras ejecutar a en s .
- $\gamma \in (0, 1]$: Factor de descuento que pondera la importancia de las recompensas futuras frente a las inmediatas.

El objetivo del agente es aprender una política $\pi(a|s)$ que maximice el retorno acumulado descontado a lo largo del tiempo. Para ello, se basa en la **Ecuación de Bellman**, que descompone el valor esperado de un estado en la recompensa inmediata más el valor esperado descontado del siguiente estado. Esta formulación recursiva es el cimiento de los algoritmos de valor y política utilizados en DRL.

2.3. Algoritmos PPO y SAC

En entornos con espacios de acciones continuos y de alta dimensionalidad, como es la distribución porcentual de capital en N activos, los algoritmos basados en redes neuronales profundas que parametrizan la política de forma directa son esenciales.

2.3.1. Proximal Policy Optimization (PPO)

El algoritmo PPO (Schulman et al., 2017) es un método de tipo Actor-Crítico (*on-policy*) reconocido por su estabilidad empírica y facilidad de sintonización. PPO optimiza una función objetivo “recortada” (*clipped surrogate objective*) que limita severamente el tamaño de la actualización de la política en cada paso de entrenamiento. Al evitar que la nueva política difiera excesivamente de la antigua, PPO previene caídas catastróficas en el desempeño. La arquitectura del agente consta de una red neuronal Actor, responsable de emitir las probabilidades de acción (o en su defecto, la media y desviación estándar de una distribución continua), y una red Crítica que estima la función de valor del estado para calcular la ventaja de la acción tomada.

2.3.2. Soft Actor-Critic (SAC)

Por otro lado, SAC (Haarnoja et al., 2018) es un algoritmo *off-policy* que integra el principio de optimización de máxima entropía. A diferencia del RL estándar, el objetivo en SAC no es solo maximizar la recompensa acumulada, sino también la entropía de la política. Esto incentiva al agente a explorar ampliamente el espacio de acciones y adoptar políticas estocásticas más robustas. SAC utiliza una estructura que incluye un Actor estocástico y múltiples redes Críticas (generalmente redes Q) para mitigar la sobrestimación

del valor. Gracias a su naturaleza *off-policy*, SAC reutiliza de forma muy eficiente los datos pasados almacenados en un *Replay Buffer*, logrando convergencias más rápidas en términos de interacción con el entorno en comparación con métodos *on-policy*.

2.4. Regímenes de Mercado y Modelos Ocultos

En la dinámica real de los mercados financieros, los retornos de los activos no son estacionarios. El mercado transita entre distintos regímenes macroeconómicos, típicamente simplificados en estados *Bull* (tendencias alcistas, baja volatilidad) y *Bear* (tendencias bajistas, alta volatilidad e incertidumbre).

Para modelar esta latencia, es común recurrir a los Modelos Ocultos de Markov (HMM, por sus siglas en inglés) (Baum and Petrie, 1966). En un HMM, el régimen actual del mercado se considera una variable oculta que obedece a las propiedades de una cadena de Markov. Sin embargo, aunque el régimen exacto no se puede observar directamente, sí se pueden observar sus emisiones, que en este contexto corresponden a los retornos históricos y la volatilidad de los activos. Mediante inferencia bayesiana, es posible calcular las probabilidades de pertenencia a un régimen *Bear* o *Bull* en cualquier instante del tiempo, proporcionando al agente DRL señales probabilísticas cruciales (incorporadas en el vector de estado s_t) para adaptar dinámicamente su aversión al riesgo y su estrategia de asignación de capital.

Capítulo 3

Metodología y Formulación del Modelo

En este capítulo se detalla la construcción y diseño del modelo propuesto para la optimización dinámica de portafolios de inversión utilizando algoritmos de Deep Reinforcement Learning (DRL). El enfoque metodológico se fundamenta en la implementación real desarrollada en Python, donde se estructuró un entorno de simulación personalizado que modela la interacción del agente con el mercado, la gestión del riesgo y las fricciones transaccionales. Se abordan los procesos de adquisición y transformación de datos, la formulación rigurosa del Proceso de Decisión de Markov Parcialmente Observable (POMDP), el diseño del entorno compatible con la interfaz Gym, y la configuración arquitectónica de los agentes PPO y SAC.

3.1. Datos y Preprocesamiento

La materia prima para el entrenamiento y evaluación de los agentes proviene de series de tiempo financieras de dos activos representativos: el índice S&P 500 (SPX), que refleja el mercado accionario tradicional, y el índice Cripto CMC200, que introduce una clase de activo alternativo con alta volatilidad y retornos potencialmente asimétricos. El horizonte temporal estudiado consta de datos semanales (163 semanas en total).

Para evitar sesgos y asegurar una correcta generalización del modelo, el conjunto de datos se particiona secuencialmente en tres subconjuntos: Entrenamiento (Train, 70 %), Validación (Val, 15 %) y Prueba (Test, 15 %). El preprocesamiento incluye la normalización Z-Score de las variables predictoras (retornos esperados, varianzas y covarianzas) para garantizar la estabilidad numérica en el entrenamiento de las redes neuronales, conservando los retornos reales sin normalizar exclusivamente para el cálculo fidedigno de la evolución del capital.

3.2. Formulación del MDP/POMDP

El problema de asignación de portafolio se modela como un Proceso de Decisión de Markov Parcialmente Observable (POMDP), definido por la tupla $\langle S, A, P, R, \gamma \rangle$, donde las dinámicas ocultas de los regímenes *Bull* y *Bear* exigen que el agente infiera el estado real del mercado a partir de observaciones parciales.

3.2.1. Espacio de Observación (S)

El vector de observación continuo, de dimensionalidad 9, suministrado al agente en el instante t , está compuesto por:

- **Capital normalizado:** x_t/x_0 , donde $x_0 = 10,000$ USD es el capital inicial.
- **Pesos previos del portafolio:** $w_{t-1} = [w_{SPX,t-1}, w_{CMC,t-1}]$, para que el agente tenga consciencia de la distribución actual y pueda optimizar el recálculo de los costos de transacción.
- **Fracción de tiempo temporal:** t/T_{window} , indicando la posición relativa dentro del horizonte de inversión.
- **Características del mercado (*features*):** Medias (μ), varianzas (σ^2) y covarianzas mixtas normalizadas de los activos bajo los modelos ocultos.

Adicionalmente, durante el entrenamiento se incorpora inyección de ruido gaussiano estocástico ($\mathcal{N}(0, 0.001)$) al vector de observación como mecanismo de *Data Augmentation*, mejorando la robustez del agente frente a variaciones inesperadas del mercado.

3.2.2. Espacio de Acción (A)

El agente emite un vector continuo $a_t \in [-1, 1]^2$. Dado que el portafolio exige estar completamente invertido (sin apalancamiento ni ventas en corto), la acción cruda es proyectada al simplex unitario (Δ^{n-1}) mediante un recorte a valores no negativos ($a_{clipped} = \text{máx}(0, a_t)$) seguido de una normalización $w_t = a_{clipped} / \sum a_{clipped}$. Si la suma resulta cercana a cero, el entorno aplica un *fallback* imponiendo una ponderación equitativa ($[0.5, 0.5]$).

3.2.3. Función de Recompensa (R)

La señal de recompensa emula matemáticamente la función objetivo del modelo de optimización clásico de GAMS, estableciendo un balance entre la maximización del retorno y la penalización por riesgo y fricciones del mercado. En cada paso t , la recompensa

se calcula como:

$$R_t = (w_t^T \mu) - \lambda(w_t^T \Sigma w_t) - c_t \quad (3.1)$$

Donde:

- $(w_t^T \mu)$ es el retorno esperado del portafolio.
- λ es el coeficiente de aversión al riesgo (establecido en 0,10).
- $(w_t^T \Sigma w_t)$ es la varianza esperada del portafolio.
- c_t representa los costos de transacción incurridos por la rotación del portafolio. Se calculan como $c_t = \sum |w_{i,t} - w_{i,t-1}| \cdot c_i$, asumiendo comisiones heterogéneas (0,5 % para SPX y 1,0 % para CMC200).

Además, se impone una penalización severa $(-10,0)$ si el capital llega a cero (ruina).

3.3. Diseño del Entorno (Gym)

El entorno personalizado `PortfolioEnv` hereda de la interfaz estándar de OpenAI Gym (ahora Gymnasium). La interacción se estructura en episodios. Durante el entrenamiento, para evitar sobreajuste temporal, se utiliza un mecanismo de inicialización aleatoria (*Random Start*) sobre una ventana deslizante de 52 semanas. En fase de evaluación (Validación y Prueba), el entorno procesa el subconjunto de datos completo de manera secuencial determinista.

La dinámica de transición actualiza el capital real en función del retorno financiero efectivo del periodo y deduce los costos transaccionales explícitamente:

$$x_{t+1} = x_t \left(1 + \sum_i (w_{i,t} \cdot R_{i,t}^{real}) - c_t \right) \quad (3.2)$$

3.4. Arquitectura y Configuración del Agente

La parametrización de las políticas se delega a redes neuronales profundas (MLP). El agente **PPO** es configurado para procesar lotes (minibatches) equivalentes a la longitud exacta de un episodio de entrenamiento, optimizando la función *clipped surrogate* cada 10 *rollouts* para garantizar la estabilidad de las estimaciones de ventaja (GAE). Se define un *clip range* de 0,2, un factor de descuento y una entropía controlada ($\text{ent_coef} = 0,01$) para mantener un nivel moderado de exploración persistente.

Para **SAC**, al ser un modelo *off-policy*, la interacción se almacena en un *Replay Buffer*. El agente optimiza redes de valor Q separadas mediante *soft updates* minimizando el error de diferencia temporal. La naturaleza de máxima entropía de SAC resulta teóricamente ventajosa para descubrir estrategias diversificadas en un entorno de mercado donde

converger prematuramente a una *corner solution* compromete el rendimiento ajustado por riesgo fuera de la muestra.

Bibliografia

- Baum, L. E. and Petrie, T. (1966). Statistical inference for probabilistic functions of finite state markov chains. *The annals of mathematical statistics*, 37(6):1554–1563.
- Bellman, R. (1957). A markovian decision process. *Journal of mathematics and mechanics*, pages 679–684.
- Haarnoja, T., Zhou, A., Abbeel, P., and Levine, S. (2018). Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. In *International conference on machine learning*, pages 1861–1870. PMLR.
- Markowitz, H. (1952). Portfolio selection. *The Journal of Finance*, 7(1):77–91.
- Schulman, J., Wolski, F., Dhariwal, P., Radford, A., and Klimov, O. (2017). Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*.
- Shannon, C. E. (1948). A mathematical theory of communication. *The Bell system technical journal*, 27(3):379–423.
- Sharpe, W. F. (1966). Mutual fund performance. *The Journal of Business*, 39(1):119–138.
- Sortino, F. A. and Price, L. N. (1994). Performance measurement in a downside risk framework. *The Journal of Investing*, 3(3):59–64.
- Sutton, R. S. and Barto, A. G. (2018). *Reinforcement learning: An introduction*. MIT press.