

Hito 2 (versión DRL): Formulación y Flujo de Trabajo para Portafolios con Regímenes Bear–Bull

Sofía Valenzuela

13 de marzo de 2026

1. Objetivo

El objetivo es **aprender** una *política de asignación de portafolio* $\pi_\theta(a_t \mid s_t)$ que, en cada periodo t , determine las proporciones w_t a invertir en cada activo, **maximizando el retorno esperado** del portafolio **ajustado por riesgo y costos de transacción**, en presencia de **regímenes de mercado** (bear/bull) **parcialmente observables**. A diferencia del esquema *Smart-Predict-then-Optimize* (SPO), aquí el agente *interactúa* con el entorno, observa s_t , ejecuta una acción $a_t \equiv w_t$, recibe una recompensa R_t y actualiza su política mediante *Deep Reinforcement Learning* (PPO o SAC) con arquitecturas recurrentes (LSTM/RNN) para manejar la parcial observabilidad.

2. Conjuntos e Índices

Sea $i \in I$ el conjunto de activos y $t \in T = \{1, \dots, T_{\text{máx}}\}$ el horizonte temporal (por ejemplo, semanal).

3. Datos y Parámetros

Retornos por activo $r_{i,t}$; probabilidades (o señales) de régimen $p_{i,\text{bull},t}$ y $p_{i,\text{bear},t}$; aversión al riesgo $\lambda > 0$; costos de transacción $c_i \geq 0$; pesos iniciales $w_{i,0}$; y, opcionalmente, momentos “mixtos” $\mu_{i,t}^{\text{mix}}$ y Σ_t^{mix} si se desean usar como *features* del estado.

4. Formulación como POMDP

Modelamos el problema como un Proceso de Decisión de Markov Parcialmente Observable (POMDP)

$$\mathcal{M} = \langle \mathcal{S}, \mathcal{A}, P, \mathcal{R}, \gamma \rangle,$$

donde $\mathcal{S}$ es el espacio de *observaciones*, $\mathcal{A}$ el espacio de *acciones*, P la dinámica de transición, $\mathcal{R}$ la función de recompensa y $\gamma \in (0, 1]$ el factor de descuento.

Estado (observación). Definimos el vector de observación como

$$s_t = \left[\text{features de } r_{i,t-L:t-1}, p_{i,\text{bull},t}, p_{i,\text{bear},t}, \mu_t^{\text{mix}}, \Sigma_t^{\text{mix}}, w_{t-1}, \text{indicadores macro} \right]. \quad (1)$$

Acción (pesos). La acción es el vector de pesos $a_t \equiv w_t = [w_{1,t}, \dots, w_{n,t}]$ con restricciones

$$\sum_{i \in I} w_{i,t} = 1, \quad w_{i,t} \geq 0. \quad (2)$$

En práctica, el actor produce *logits* ζ_t y se proyecta al simplex mediante **softmax**:

$$w_{i,t} = \frac{\exp(\zeta_{i,t})}{\sum_{j \in I} \exp(\zeta_{j,t})}. \quad (3)$$

Transición. La transición $P(s_{t+1} | s_t, a_t)$ está inducida por la dinámica del mercado (retornos y probabilidades de régimen bear–bull) y el efecto del rebalanceo de portafolio.

Recompensa. Replicamos la estructura del modelo GAMS (retorno menos riesgo y fricción), con opción de bono de diversificación:

$$R_t = \underbrace{\sum_i w_{i,t} r_{i,t+1}}_{\text{retorno}} - \underbrace{\lambda w_t^\top \Sigma_t^{\text{mix}} w_t}_{\text{riesgo}} - \underbrace{\sum_i c_i |w_{i,t} - w_{i,t-1}|}_{\text{costos de transacción}} + \underbrace{\eta_H \left(- \sum_i w_{i,t} \log w_{i,t} \right)}_{H(w_t)}, \quad (4)$$

donde $\eta_H \geq 0$ controla el incentivo de diversificación (opcional).

5. Arquitectura del Agente (PPO/SAC con RNN)

Actor recurrente π_θ (LSTM/RNN) que, dado s_t y su estado oculto, devuelve logits ζ_t (o los parámetros de una política estocástica continua); **Crítico** $V_\phi(s_t)$ (PPO) o redes **Q** recurrentes Q_{ψ_1}, Q_{ψ_2} (SAC). El mapeo **softmax** asegura $w_t \in \Delta^{n-1}$.

6. Objetivo del Agente

El objetivo es maximizar el retorno descontado:

$$J(\pi_\theta) = \mathbb{E}_{\pi_\theta} \left[\sum_{t=0}^{T_{\text{máx}}} \gamma^t R_t \right], \quad (5)$$

con R_t dado por (4).

7. Flujo de Trabajo del Modelo (Interacción y Entrenamiento)

Algorithm 1 DRL para Portafolios con Regímenes Bear–Bull (POMDP, Acciones Continuas)

```

1: Entrada: datos de mercado  $\{r_{i,t}\}$ , señales/probabilidades de régimen  $\{p_{i,\cdot,t}\}$ ,  $\lambda$ ,  $\{c_i\}$ ,  $\eta_H$ ,  $\gamma$ 
2: Inicializar: pesos  $w_0$ , parámetros  $\theta, \phi$  (y  $\psi_1, \psi_2$  en SAC), estados ocultos LSTM en cero
3: for epoch = 1, ...,  $N_{\text{epochs}}$  do
4:   Reiniciar entorno y construir  $s_0$ 
5:   for t = 0, ...,  $T_{\text{máx}} - 1$  do
6:     (Actor RNN) generar logits  $\zeta_t \leftarrow \pi_\theta(s_t)$  y mapear  $w_t = \text{softmax}(\zeta_t)$ 
7:     Ejecutar  $w_t$ ; observar  $r_{t+1}$  y (si aplica)  $p_{i,\cdot,t+1}$ 
8:     Calcular  $R_t$  mediante (4)
9:     Construir  $s_{t+1}$  e insertar transición en buffer (on-policy para PPO; replay secuencial para SAC)
10:    if PPO then
11:      Calcular ventajas (GAE) y targets; actualizar  $\theta, \phi$  vía pérdida clipped usando mini-batches de secuencias
12:    else ▷ SAC
13:      Muestrear secuencias del replay con burn-in; actualizar  $Q_{\psi_1}, Q_{\psi_2}$  y política  $\pi_\theta$  (término soft) con redes objetivo
14:    Evaluar fuera de muestra: retorno, Sharpe, MaxDD, turnover, riesgo

```

8. Relación con el Modelo de GAMS

La recompensa (4) replica la función objetivo del modelo GAMS: *retorno* menos *riesgo* ($w_t^\top \Sigma_t^{\text{mix}} w_t$) menos *costos de transacción* L^1 . Las probabilidades/reglas bear–bull que, en GAMS, forman los *momentos mixtos* ahora alimentan el *estado* y la *transición*. La política aprendida sustituye la resolución QP/NLP en cada t , manteniendo el mismo significado económico del *trade-off* retorno–riesgo–fricción y añadiendo adaptatividad.

9. Validación y Métricas

Validación *rolling*: entrenar en ventanas deslizantes y evaluar fuera de muestra. Reportar retorno anualizado, volatilidad, índices de Sharpe/Sortino, *max drawdown*, *turnover* y costo neto. Realizar estudios de sensibilidad en λ , c_i y η_H , y pruebas de ablación (sin señales bear–bull; sin término de riesgo; sin costos).