

Formulación MDP del problema de portafolio con costos de transacción

Consideremos un conjunto finito de activos I , un horizonte discreto $t = 1, \dots, T$, y un capital inicial $x_1 > 0$. El problema de portafolio con costos de transacción proporcional puede modelarse como un Proceso de Decisión de Markov (MDP) en tiempo discreto.

1. Definición del MDP

Definimos el MDP como $\mathcal{M} = (\mathcal{S}, \mathcal{A}, \mathcal{P}, r, \gamma)$, donde:

Espacio de estados $\mathcal{S}$. El estado al inicio del periodo t se define como

$$s_t = (x_t, w_{t-1}, t),$$

donde:

- $x_t \in \mathbb{R}^+$ es el capital disponible al inicio de t .
- $w_{t-1} = (w_{i,t-1})_{i \in I}$ son los pesos vigentes del portafolio al cierre de $t-1$, con $w_{i,t-1} \geq 0$, $\sum_{i \in I} w_{i,t-1} = 1$.
- t es el índice de tiempo (opcionalmente normalizado t/T para efectos numéricos).

Por lo tanto, el espacio de estados es

$$\mathcal{S} = \{(x, w, t) : x \geq 0, w \in \Delta^{|I|-1}, t \in \{1, \dots, T\}\},$$

donde $\Delta^{|I|-1}$ denota el simplex de dimensión $|I| - 1$.

Espacio de acciones $\mathcal{A}$. La acción en el periodo t es la elección de un nuevo vector de pesos $w_t = (w_{i,t})_{i \in I}$:

$$a_t = w_t \in \mathcal{A},$$

sujeto a

$$\begin{aligned} w_{i,t} &\geq 0, \\ \sum_{i \in I} w_{i,t} &= 1. \end{aligned}$$

En términos de RL continuo, $\mathcal{A}$ es también un simplex; en la implementación se trabaja con una parametrización continua que se proyecta al simplex.

Proceso de retornos. Sea $R_t = (R_{i,t})_{i \in I}$ el vector de retornos en el intervalo $(t, t + 1]$. Supondremos que

$$R_t \sim D_t(\mu_t, \Sigma_t),$$

donde:

$$\mu_t = (\mu_{i,t})_{i \in I},$$

$$\Sigma_t = [\sigma_{ij,t}]_{i,j \in I}.$$

La distribución D_t puede ser, por ejemplo, una distribución gaussiana multivariada o una mezcla condicionada a regímenes (bear/bull). Lo importante es que, dado t , la distribución de R_t es conocida o estimada a partir de datos históricos.

Costos de transacción. Dado el estado (x_t, w_{t-1}, t) y la acción w_t , definimos el cambio de pesos

$$\Delta w_{i,t} = w_{i,t} - w_{i,t-1},$$

y la rotación total (en pesos del portafolio) como

$$\text{turn}_t = \sum_{i \in I} |\Delta w_{i,t}|.$$

Sea $c_i \geq 0$ la tasa de costo de transacción por unidad de rotación del activo i . El costo monetario en el periodo t es

$$C_t(x_t, w_{t-1}, w_t) = x_t \sum_{i \in I} c_i |\Delta w_{i,t}|.$$

Dinámica de transición $\mathcal{P}$. Dado el estado actual $s_t = (x_t, w_{t-1}, t)$, la acción $a_t = w_t$ y el retorno aleatorio R_t , definimos:

1. Retorno del portafolio en el periodo t :

$$r_t^{\text{port}} = \sum_{i \in I} w_{i,t} R_{i,t} = w_t^\top R_t.$$

2. Capital al inicio de $t + 1$:

$$x_{t+1} = x_t \left(1 + w_t^\top R_t - \sum_{i \in I} c_i |\Delta w_{i,t}| \right).$$

3. Pesos para el siguiente estado: w_t pasa a ser la componente de pesos del siguiente estado.

4. Índice temporal: $t \rightarrow t + 1$.

Por tanto, el kernel de transición queda implícitamente definido por:

$$S_{t+1} = (x_{t+1}, w_t, t + 1) = F(S_t, A_t, R_t),$$

con $R_t \sim D_t(\mu_t, \Sigma_t)$.

Función de recompensa $r(s, a)$. Existen dos enfoques naturales y compatibles con el modelo de media-varianza con costos:

1. Reward tipo media-varianza (determinístico):

$$r_t(s_t, a_t) = \sum_{i \in I} w_{i,t} \mu_{i,t} - \lambda \sum_{i,j \in I} w_{i,t} w_{j,t} \sigma_{ij,t} - \sum_{i \in I} c_i |\Delta w_{i,t}|,$$

donde $\lambda > 0$ es el parámetro de aversión al riesgo. Con $\gamma = 1$ y horizonte finito, el funcional $\sum_{t=1}^T r_t(s_t, a_t)$ reproduce la función objetivo de media-varianza con costos.

2. Reward monetario (realizado):

$$\tilde{r}_t(s_t, a_t, R_t) = x_{t+1} - x_t = x_t \left(w_t^\top R_t - \sum_{i \in I} c_i |\Delta w_{i,t}| \right),$$

y el agente observa realizaciones de $\tilde{r}_t$ a partir de los retornos históricos o simulados.

En ambos casos, el objetivo del agente es maximizar la suma descontada de recompensas:

$$J(\pi) = \mathbb{E}_\pi \left[\sum_{t=1}^T \gamma^{t-1} r_t(S_t, A_t) \right],$$

para una política π .

1.2 Políticas y funciones de valor

Una política estocástica se define como

$$\pi(w|x, w_{t-1}, t) = \Pr\{A_t = w | X_t = x, W_{t-1} = w_{t-1}, t\},$$

mientras que una política determinista se modela como

$$\mu : \mathcal{S} \rightarrow \mathcal{A}, \quad A_t = \mu(S_t).$$

Dada una política π , la función valor de estado es:

$$V^\pi(x, w_{t-1}, t) = \mathbb{E}_\pi \left[\sum_{\tau=t}^T \gamma^{\tau-t} r_\tau(S_\tau, A_\tau) \middle| S_t = (x, w_{t-1}, t) \right].$$

La ecuación de Bellman para V^π (con horizonte finito y $t < T$) es:

$$V^\pi(s_t) = \mathbb{E}_{A_t \sim \pi} [r_t(s_t, A_t) + \gamma \mathbb{E}_{R_t} [V^\pi(S_{t+1})]].$$

Análogamente, la función valor acción-estado Q^π es:

$$Q^\pi(s_t, a_t) = \mathbb{E} \left[\sum_{\tau=t}^T \gamma^{\tau-t} r_\tau(S_\tau, A_\tau) \middle| S_t = s_t, A_t = a_t \right],$$

y satisface la ecuación de Bellman correspondiente.

Adicionalmente, para evaluar la calidad relativa de una acción respecto al valor promedio del estado, definimos la **Función de Ventaja (Advantage)**:

$$A^\pi(s_t, a_t) = Q^\pi(s_t, a_t) - V^\pi(s_t).$$

Empíricamente, en la arquitectura de algoritmos tipo Actor-Crítico (como PPO), esta ventaja se estima mediante la diferencia temporal:

$$A_t \approx r_t + \gamma V^\pi(S_{t+1}) - V^\pi(S_t).$$

Las funciones óptimas se definen por

$$V^*(s) = \max_{\pi} V^\pi(s),$$

$$Q^*(s, a) = \max_{\pi} Q^\pi(s, a),$$

y una política óptima π^* cumple

$$\pi^*(s) \in \arg \max_a Q^*(s, a).$$

2. Metodología de implementación DRL (PPO y SAC)

A continuación se presenta una metodología paso a paso para implementar este MDP de portafolio con costos de transacción usando aprendizaje por refuerzo profundo (DRL) con stable baselines3, PyTorch y los algoritmos PPO y SAC. La metodología se organiza en etapas coherentes desde la construcción del entorno hasta la comparación con la solución de referencia obtenida vía GAMS en un esquema de rolling horizon.

2.1. Etapa 1: Preparación de datos y estimación de parámetros

1. **Datos de retornos.** Reunir series históricas semanales (o en la frecuencia de trabajo) de retornos $R_{i,t}$ para todos los activos $i \in I$ en el horizonte de entrenamiento.
2. **Estimación de momentos por periodo.** Para cada periodo t , estimar:

$$\mu_t = \mathbb{E}[R_t],$$

$$\Sigma_t = \text{Cov}(R_t),$$

utilizando:

- Un modelo condicional con regímenes (bear/bull) y mezcla de probabilidades, o
- Ventanas móviles de datos históricos.

Estos objetos μ_t y Σ_t son equivalentes a los parámetros μ_{mix} y Σ_{mix} utilizados en el modelo GAMS.

3. **Partición train/validation/test.** Dividir la serie de tiempo total en tres segmentos ordenados:
 - Train: periodos iniciales para aprendizaje del agente.
 - Validation: tramo intermedio para selección de hiperparámetros y control de sobreajuste.
 - Test: tramo final para evaluar error de generalización y desempeño out-of-sample.

2.2. Etapa 2: Definición del entorno MDP (Gym-like)

Implementar un entorno en la interfaz tipo Gym, por ejemplo `PortfolioEnv`, con los métodos `reset()` y `step(action)`:

1. **Observaciones.** Definir el vector de observación en t como

$$o_t = [x_t, w_{t-1}, t/T, \text{features}_t],$$

donde features_t se define explícitamente como los parámetros normalizados del modelo GAMS:

$$\text{features}_t = [\text{norm_}\mu_{\text{mix}}(i, t), \text{norm_var_mix}(i, t), \text{norm_cov_mix}(t)].$$

Normalizar o escalar las observaciones para estabilidad numérica.

2. **Acciones.** El agente devuelve un vector continuo $\tilde{a}_t \in \mathbb{R}^{|I|}$ que se transforma a pesos factibles:

$$w_{i,t} = \frac{\max(0, \tilde{a}_{i,t})}{\sum_{j \in I} \max(0, \tilde{a}_{j,t})},$$

garantizando $w_{i,t} \geq 0$ y $\sum_i w_{i,t} = 1$.

3. **Step.** Dado el estado interno (x_t, w_{t-1}, t) y la acción w_t :

(a) Generar o leer R_t :

- Opción simulación: muestrear $R_t \sim D_t(\mu_t, \Sigma_t)$.
- Opción histórica: tomar el retorno observado en t .

(b) Calcular el costo de transacción:

$$C_t = x_t \sum_{i \in I} c_i |w_{i,t} - w_{i,t-1}|.$$

(c) Actualizar el capital:

$$x_{t+1} = x_t \left(1 + w_t^\top R_t - \sum_i c_i |w_{i,t} - w_{i,t-1}| \right).$$

(d) Actualizar pesos: $w_t^{\text{next}} = w_t$.

(e) Definir el reward r_t según la opción elegida:

$$r_t = \sum_i w_{i,t} \mu_{i,t} - \lambda \sum_{i,j} w_{i,t} w_{j,t} \sigma_{ij,t} - \sum_i c_i |\Delta w_{i,t}| \quad (\text{media-varianza})$$

o $x_{t+1} - x_t$ (monetario realizado).


(f) Construir la observación o_{t+1} y marcar `done = True` cuando $t = T$.

4. **Reset.** En `reset()`, inicializar:

$$x_1 = x_{\text{init}}, \quad w_0 = w_{\text{init}}, \quad t = 1,$$

y devolver la observación inicial o_1 .

Diagrama de Arquitectura PPO



2.3. Etapa 3: Definición de agentes y arquitecturas (PPO y SAC)

Espacio de observación y acción. Configurar en stable baselines3:

- Box continuo para el espacio de observación, con límites apropiados.
- Box continuo para el espacio de acción, con límites, por ejemplo, en $[-1, 1]$ y posterior proyección al simplex como se indicó.

PPO (on-policy, policy gradient).

- Usar PPO con política tipo MlpPolicy.
- Arquitectura sugerida: 2–3 capas densas intermedias con activaciones no lineales (ReLU o Tanh), tamaño moderado (p.ej., 64–128 neuronas) para evitar sobreparametrizar.
- Hiperparámetros a calibrar: tamaño de batch, longitud de rollouts, coeficiente de entropía, clip range, tasa de aprendizaje, coeficiente de valor.

SAC (off-policy, actor–critic maximum-entropy).

- Usar SAC con política MlpPolicy y acción continua.
- Arquitecturas similares para actor y críticos (2–3 capas densas).
- Hiperparámetros clave: tasa de aprendizaje, tau para target networks, temperatura de entropía (fija o automática).

Funciones de Pérdida (Loss) para Backpropagation. Para materializar el aprendizaje, los algoritmos optimizan las siguientes funciones de pérdida mediante gradiente descendente:

Loss de PPO: El agente PPO actualiza su política π_θ maximizando una función objetivo recortada (Clipped Surrogate Objective) para evitar actualizaciones destructivas:

$$L^{CLIP}(\theta) = \hat{\mathbb{E}}_t \left[\min \left(\rho_t(\theta) \hat{A}_t, \text{clip}(\rho_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right) \right]$$

donde $\rho_t(\theta) = \frac{\pi_\theta(a_t|s_t)}{\pi_{\theta_{old}}(a_t|s_t)}$ es la razón de probabilidad y ϵ es el rango de recorte. Simultáneamente, el Crítico V_ϕ se actualiza minimizando el error cuadrático medio respecto a los retornos calculados:

$$L^{VF}(\phi) = \hat{\mathbb{E}}_t \left[(V_\phi(s_t) - V_t^{\text{target}})^2 \right]$$

Loss de SAC: En SAC, los parámetros de las redes críticas gemelas Q_{ϕ_i} se optimizan minimizando el Error Cuadrático Medio de la ecuación de Bellman *Soft*:

$$L_Q(\phi_i) = \mathbb{E}_{(s_t, a_t) \sim \mathcal{D}} \left[\left(Q_{\phi_i}(s_t, a_t) - \left(r_t + \gamma \left(\min_{j=1,2} Q_{\phi_{\text{target},j}}(s_{t+1}, \tilde{a}_{t+1}) - \alpha \log \pi_\theta(\tilde{a}_{t+1}|s_{t+1}) \right) \right) \right)^2 \right]$$

Por su parte, el Actor π_θ actualiza sus pesos minimizando la pérdida de política basada en la divergencia Kullback-Leibler, lo que se traduce en:

$$L_\pi(\theta) = \mathbb{E}_{s_t \sim \mathcal{D}, \tilde{a}_t \sim \pi_\theta} \left[\alpha \log \pi_\theta(\tilde{a}_t|s_t) - \min_{j=1,2} Q_{\phi_j}(s_t, \tilde{a}_t) \right]$$

Capacidad de los agentes y error de generalización. El objetivo es minimizar el error de generalización (diferencia entre desempeño en entrenamiento y en test). Para ello:

1. **Control de capacidad.** Ajustar la profundidad y el ancho de las redes para que capturen patrones relevantes sin sobreajuste evidente.
2. **Regularización implícita.**
 - En PPO: controlar clip range y tasa de aprendizaje para evitar updates agresivos.
 - En SAC: ajustar la temperatura de entropía para evitar políticas excesivamente deterministas durante el entrenamiento.
3. **Evaluación en validación.** Durante el entrenamiento, usar un evaluation callback que mida periódicamente:

$$\hat{J}_{\text{val}}(\theta) = \frac{1}{N_{ep}} \sum_{e=1}^{N_{ep}} (\text{retorno acumulado en episodios de validación}),$$

y seleccionar el modelo con mejor desempeño en validación.


4. **Walk-forward y múltiples semillas.** Repetir el entrenamiento con distintas semillas iniciales y, opcionalmente, distintos sub-períodos de entrenamiento para medir robustez y estabilidad.

Definiciones para Arquitectura SAC. Para el agente SAC (Soft Actor-Critic), el objetivo se expande para maximizar tanto el retorno esperado como la entropía de la política. El proceso incluye componentes específicos para su naturaleza off-policy:

- **Replay Buffer ($\mathcal{D}$):** Memoria donde se almacenan las transiciones observadas (O_t, a_t, r_t, O_{t+1}) . Permite reutilizar experiencia pasada.
- **Doble Crítico Soft (Q_{ϕ_1}, Q_{ϕ_2}):** Dos redes neuronales que estiman el valor acción-estado continuo $Q(O_t, a_t)$. Se utiliza el mínimo de ambas estimaciones para evitar el sesgo de sobreestimación del valor.
- **Optimizador SAC (α, τ):** Incluye el cálculo y optimización de las **Redes Target** mediante una media móvil exponencial con tasa τ , y la gestión del **Coefficiente de Entropía (α)**, el cual controla la temperatura de exploración.

A continuación se presenta la arquitectura conceptual para el agente SAC, la cual interactúa con el mismo entorno definido previamente:

Diagrama de Arquitectura SAC



2.4. Etapa 4: Diseño de pruebas de comparación

Se propone un esquema de comparación con las siguientes referencias:

1. Base determinista (GAMS, media-varianza con costos).

- Resolver el modelo media-varianza con costos de transacción en GAMS para ventanas móviles de longitud H (por ejemplo, 26–52 semanas) usando las estimaciones μ_t y Σ_t disponibles hasta el tiempo actual.

- En cada fecha t :
 - (a) Construir una ventana rolling $[t, t + H - 1]$ con parámetros pronosticados.
 - (b) Resolver el problema determinista en esa ventana (maximización de media-varianza con costos).
 - (c) Aplicar sólo la primera decisión w_t^{GAMS} .
 - (d) Avanzar al siguiente periodo $t + 1$ y repetir (esquema de rolling horizon).
- Evolucionar el capital x_t^{GAMS} con los retornos realizados y registrar la trayectoria.

2. Agentes DRL (PPO y SAC).

- Para cada agente entrenado (PPO y SAC), fijar los parámetros finales θ^* y evaluar en el periodo de test:

$$x_t^{\text{PPO}}, \quad x_t^{\text{SAC}}, \quad t \in \text{test},$$

usando retornos realizados y el mismo esquema de costos.

3. Benchmarks adicionales.

- Portafolio buy-and-hold (por ejemplo, 50/50).
- Portafolio 50/50 con rebalanceo periódico fijo.

2.5. Etapa 5: Métricas de evaluación y comparación

Para comparar GAMS vs. PPO vs. SAC vs. benchmarks se propone:

- Retorno acumulado:

$$\text{RetAcum} = \frac{x_T}{x_1} - 1.$$

- Volatilidad del portafolio: desviación estándar de los retornos de portafolio r_t^{port} .
- Medidas riesgo-retorno: ratio de Sharpe, semivarianza, drawdowns máximos.
- Rotación y costos: promedio de turn_t y costo acumulado de transacción.
- Error de generalización: diferencia entre métricas en train/validation y test para cada agente, y comparación del agente DRL contra la solución rolling de GAMS:

$$\text{Regret}_{\text{GAMS}}^{\text{DRL}} = \text{RetAcum}_{\text{GAMS}} - \text{RetAcum}_{\text{DRL}},$$

evaluado en el periodo de test.

2.6. Etapa 6: Síntesis

La metodología propuesta permite:

1. Formular el problema de portafolio con costos de transacción como un MDP bien definido.

2. Entrenar agentes DRL (PPO y SAC) que aprenden políticas π_θ o μ_θ a partir de datos históricos o simulados.
3. Controlar la capacidad de los agentes y el error de generalización mediante particiones temporales, callbacks de evaluación y experimentos con múltiples semillas.
4. Comparar de forma rigurosa el desempeño de los agentes DRL contra la solución determinista GAMS en un esquema de rolling horizon, y contra benchmarks simples, tanto en términos de retorno esperado como de riesgo y costos de transacción.

3. Apéndice: Preparación de Datos y Estimación de Parámetros

Este documento detalla la ejecución técnica de la **Etapa 1** definida en la Memoria de Referencia (Documento 02), adaptándola a los activos SPX y CMC200 para un horizonte de $T = 163$ semanas.

4. Datos Fuente y Horizonte Temporal

El proyecto utiliza series históricas semanales para $T = 163$ periodos. Los insumos base son:

- **Retornos Netos** ($R_{i,t}$): Observaciones semanales de SPX y CMC200.
- **Probabilidades HMM** ($P_{i,k,t}$): Señales exógenas de régimen (Bear/Bull).

5. Partición del Dataset (Rigor DRL)

Siguiendo la metodología *walk-forward* de la Biblia, dividimos las 163 semanas para garantizar la capacidad de generalización:

Conjunto	Rango (semanas)	Propósito
Entrenamiento (Train)	1 - 114 (70 %)	Aprendizaje de la política.
Validación (Val)	115 - 138 (15 %)	Ajuste de hiperparámetros.
Prueba (Test)	139 - 163 (15 %)	Evaluación out-of-sample vs GAMS.

6. Estimación de Parámetros Mix

Para cada periodo t , se calculan las expectativas de mercado mediante una ventana expansiva $(1 \dots t)$.

6.1. Estimación de Momentos por Régimen

Para cada activo i bajo el régimen k , los momentos se estiman ponderando cada observación histórica por su probabilidad de pertenencia al régimen:

$$\hat{\mu}_{i,k,t} = \frac{\sum_{m=1}^t P_{i,k,m} R_{i,m}}{\sum_{m=1}^t P_{i,k,m}} \quad (1)$$

$$\hat{\sigma}_{i,j,k,t} = \frac{\sum_{m=1}^t P_{i,k,m} (R_{i,m} - \hat{\mu}_{i,k,t})(R_{j,m} - \hat{\mu}_{j,k,t})}{\sum_{m=1}^t P_{i,k,m}} \quad (2)$$

6.2. Construcción de Variables Mix

Integramos la incertidumbre del régimen en una única señal de media y riesgo:

$$\mu_{mix,i,t} = \sum_k P_{i,k,t} \cdot \hat{\mu}_{i,k,t} \quad (3)$$

$$\sigma_{mix,i,j,t} = \sum_k P_{i,k,t} \cdot \hat{\sigma}_{i,j,k,t} \quad (4)$$

Estas variables simplifican la tarea del agente al entregarle la información ya integrada.

7. Normalización Z-Score de Observaciones

Aplicamos estandarización expansiva para asegurar estabilidad numérica. Para cada variable $x_{mix,t}$, calculamos su versión normalizada:

$$z(x)_{mix,t} = \frac{x_{mix,t} - \mu(x)_{mix,t}}{\sigma(x)_{mix,t}} \quad (5)$$

8. Parámetros del Modelo y Configuración Base

Para asegurar la comparabilidad con el modelo GAMS original, se registran las siguientes constantes:

- **Capital Inicial (x_0):** 10,000 USD.
- **Pesos Iniciales (w_0):** 50 % SPX / 50 % CMC200.
- **Costos de Transacción (c_i):** SPX (0,5 %), CMC200 (1,0 %).
- **Aversión al Riesgo (λ):**
 - Grilla GAMS: {0,05, 0,10, 0,25, 0,50, 1,00}.
 - Selección DRL: $\lambda = 0,10$.