

1 Formulación MDP del problema de portafolio con costos de transacción

Consideremos un conjunto finito de activos $\mathcal{I}$, un horizonte discreto $t = 1, \dots, T$, y un capital inicial $x_1 > 0$. El problema de portafolio con costos de transacción proporcional puede modelarse como un Proceso de Decisión de Markov (MDP) en tiempo discreto.

1.1 Definición del MDP

Definimos el MDP como

$$\mathcal{M} = (\mathcal{S}, \mathcal{A}, P, r, \gamma),$$

donde:

Espacio de estados $\mathcal{S}$. El estado al inicio del periodo t se define como

$$s_t = (x_t, w_{t-1}, t),$$

donde:

- $x_t \in R_+$ es el capital disponible al inicio de t .
- $w_{t-1} = (w_{i,t-1})_{i \in \mathcal{I}}$ son los pesos vigentes del portafolio al cierre de $t - 1$, con

$$w_{i,t-1} \geq 0, \quad \sum_{i \in \mathcal{I}} w_{i,t-1} = 1.$$

- t es el índice de tiempo (opcionalmente normalizado t/T para efectos numéricos).

Por lo tanto, el espacio de estados es

$$\mathcal{S} = \{(x, w, t) : x \geq 0, w \in \Delta^{|\mathcal{I}|-1}, t \in \{1, \dots, T\}\},$$

donde $\Delta^{|\mathcal{I}|-1}$ denota el simplex de dimensión $|\mathcal{I}| - 1$.

Espacio de acciones $\mathcal{A}$. La acción en el periodo t es la elección de un nuevo vector de pesos $w_t = (w_{i,t})_{i \in \mathcal{I}}$:

$$a_t = w_t \in \mathcal{A},$$

sujeto a

$$w_{i,t} \geq 0, \quad \sum_{i \in \mathcal{I}} w_{i,t} = 1.$$

En términos de RL continuo, $\mathcal{A}$ es también un simplex; en la implementación se trabaja con una parametrización continua que se proyecta al simplex.

Proceso de retornos. Sea $R_t = (R_{i,t})_{i \in \mathcal{I}}$ el vector de retornos en el intervalo $(t, t + 1]$. Supondremos que

$$R_t \sim D_t(\mu_t, \Sigma_t),$$

donde:

$$\mu_t = (\mu_{i,t})_{i \in \mathcal{I}}, \quad \Sigma_t = [\sigma_{ij,t}]_{i,j \in \mathcal{I}}.$$

La distribución D_t puede ser, por ejemplo, una distribución gaussiana multivariada o una mezcla condicionada a regímenes (bear/bull). Lo importante es que, dado t , la distribución de R_t es conocida o estimada a partir de datos históricos.

Costos de transacción. Dado el estado (x_t, w_{t-1}, t) y la acción w_t , definimos el cambio de pesos

$$\Delta w_{i,t} = w_{i,t} - w_{i,t-1},$$

y la rotación total (en pesos del portafolio) como

$$turn_t = \sum_{i \in \mathcal{I}} |\Delta w_{i,t}|.$$

Sea $c_i \geq 0$ la tasa de costo de transacción por unidad de rotación del activo i . El costo monetario en el periodo t es

$$C_t(x_t, w_{t-1}, w_t) = x_t \sum_{i \in \mathcal{I}} c_i |\Delta w_{i,t}|.$$

Dinámica de transición P . Dado el estado actual $s_t = (x_t, w_{t-1}, t)$, la acción $a_t = w_t$ y el retorno aleatorio R_t , definimos:

1. Retorno del portafolio en el periodo t :

$$r_t^{port} = \sum_{i \in \mathcal{I}} w_{i,t} R_{i,t} = w_t^\top R_t.$$

2. Capital al inicio de $t + 1$:

$$x_{t+1} = x_t \left(1 + w_t^\top R_t - \sum_{i \in \mathcal{I}} c_i |\Delta w_{i,t}| \right).$$

3. Pesos para el siguiente estado: w_t pasa a ser la componente de pesos del siguiente estado.
4. Índice temporal: $t \rightarrow t + 1$.

Por tanto, el kernel de transición queda implícitamente definido por:

$$S_{t+1} = (x_{t+1}, w_t, t + 1) = F(S_t, A_t, R_t),$$

con $R_t \sim D_t(\mu_t, \Sigma_t)$.

Función de recompensa $r(s, a)$. Existen dos enfoques naturales y compatibles con el modelo de media-varianza con costos:

1. **Reward tipo media-varianza (determinístico):**

$$r_t(s_t, a_t) = \sum_{i \in \mathcal{I}} w_{i,t} \mu_{i,t} - \lambda \sum_{i,j \in \mathcal{I}} w_{i,t} w_{j,t} \sigma_{ij,t} - \sum_{i \in \mathcal{I}} c_i |\Delta w_{i,t}|,$$

donde $\lambda > 0$ es el parámetro de aversión al riesgo. Con $\gamma = 1$ y horizonte finito, el funcional $\sum_{t=1}^T r_t(s_t, a_t)$ reproduce la función objetivo de media-varianza con costos.

2. **Reward monetario (realizado):**

$$\tilde{r}_t(s_t, a_t, R_t) = x_{t+1} - x_t = x_t \left(w_t^\top R_t - \sum_{i \in \mathcal{I}} c_i |\Delta w_{i,t}| \right),$$

y el agente observa realizaciones de $\tilde{r}_t$ a partir de los retornos históricos o simulados.

En ambos casos, el objetivo del agente es maximizar la suma descontada de recompensas:

$$J(\pi) = E_\pi \left[\sum_{t=1}^T \gamma^{t-1} r_t(S_t, A_t) \right],$$

para una política π .

1.2 Políticas y funciones de valor

Una política estocástica se define como

$$\pi(w \mid x, w_{t-1}, t) = \Pr\{A_t = w \mid X_t = x, W_{t-1} = w_{t-1}, t\},$$

mientras que una política determinista se modela como

$$\mu : \mathcal{S} \rightarrow \mathcal{A}, \quad A_t = \mu(S_t).$$

Dada una política π , la función valor de estado es:

$$V^\pi(x, w_{t-1}, t) = E_\pi \left[\sum_{\tau=t}^T \gamma^{\tau-t} r_\tau(S_\tau, A_\tau) \mid S_t = (x, w_{t-1}, t) \right].$$

La ecuación de Bellman para V^π (con horizonte finito y $t < T$) es:

$$V^\pi(s_t) = E_{A_t \sim \pi} \left[r_t(s_t, A_t) + \gamma E_{R_t} [V^\pi(S_{t+1})] \right].$$

Análogamente, la función valor acción-estado Q^π es:

$$Q^\pi(s_t, a_t) = E \left[\sum_{\tau=t}^T \gamma^{\tau-t} r_\tau(S_\tau, A_\tau) \mid S_t = s_t, A_t = a_t \right],$$

y satisface la ecuación de Bellman correspondiente.

Las funciones óptimas se definen por

$$V^*(s) = \max_{\pi} V^{\pi}(s), \quad Q^*(s, a) = \max_{\pi} Q^{\pi}(s, a),$$

y una política óptima π^* cumple

$$\pi^*(s) \in \arg \max_a Q^*(s, a).$$

2 Metodología de implementación DRL (PPO y SAC)

A continuación se presenta una metodología paso a paso para implementar este MDP de portafolio con costos de transacción usando aprendizaje por refuerzo profundo (DRL) con `stable_baselines3`, `PyTorch` y los algoritmos PPO y SAC. La metodología se organiza en etapas coherentes desde la construcción del entorno hasta la comparación con la solución de referencia obtenida vía GAMS en un esquema de *rolling horizon*.

2.1 Etapa 1: Preparación de datos y estimación de parámetros

1. **Datos de retornos.** Reunir series históricas semanales (o en la frecuencia de trabajo) de retornos $R_{i,t}$ para todos los activos $i \in \mathcal{I}$ en el horizonte de entrenamiento.
2. **Estimación de momentos por periodo.** Para cada periodo t , estimar:

$$\mu_t = E[R_t], \quad \Sigma_t = Cov(R_t),$$

utilizando:

- Un modelo condicional con regímenes (bear/bull) y mezcla de probabilidades, o
- Ventanas móviles de datos históricos.

Estos objetos μ_t y Σ_t son equivalentes a los parámetros `mu_mix` y `sigma_mix` utilizados en el modelo GAMS.

3. **Partición train/validation/test.** Dividir la serie de tiempo total en tres segmentos ordenados:
 - *Train*: periodos iniciales para aprendizaje del agente.
 - *Validation*: tramo intermedio para selección de hiperparámetros y control de sobreajuste.
 - *Test*: tramo final para evaluar error de generalización y desempeño out-of-sample.

2.2 Etapa 2: Definición del entorno MDP (Gym-like)

Implementar un entorno en la interfaz tipo Gym, por ejemplo `PortfolioEnv`, con los métodos `reset()` y `step(action)`:

1. **Observaciones.** Definir el vector de observación en t como

$$o_t = [x_t, w_{t-1}, t/T, features_t],$$

donde `features_t` puede incluir:

- La media condicional μ_t .
- Elementos de Σ_t (o parámetros resumidos).
- Variables de mercado adicionales (índices de volatilidad, etc.).

Normalizar o escalar las observaciones para estabilidad numérica.

2. **Acciones.** El agente devuelve un vector continuo $\tilde{a}_t \in R^{|\mathcal{I}|}$ que se transforma a pesos factibles:

$$w_{i,t} = \frac{\max\{0, \tilde{a}_{i,t}\}}{\sum_{j \in \mathcal{I}} \max\{0, \tilde{a}_{j,t}\}},$$

garantizando $w_{i,t} \geq 0$ y $\sum_i w_{i,t} = 1$.

3. **Step.** Dado el estado interno (x_t, w_{t-1}, t) y la acción w_t :

- (a) Generar o leer R_t :
 - Opción simulación: muestrear $R_t \sim D_t(\mu_t, \Sigma_t)$.
 - Opción histórica: tomar el retorno observado en t .
- (b) Calcular el costo de transacción:

$$C_t = x_t \sum_{i \in \mathcal{I}} c_i |w_{i,t} - w_{i,t-1}|.$$

- (c) Actualizar el capital:

$$x_{t+1} = x_t \left(1 + w_t^\top R_t - \sum_i c_i |w_{i,t} - w_{i,t-1}| \right).$$

- (d) Actualizar pesos: $w_t^{next} = w_t$.
- (e) Definir el reward r_t según la opción elegida:

$$r_t = \{ \sum_i w_{i,t} \mu_{i,t} - \lambda \sum_{i,j} w_{i,t} w_{j,t} \sigma_{ij,t} - \sum_i c_i |\Delta w_{i,t}|, (media-varianza) x_{t+1} - x_t, (monetariorealizad$$

- (f) Construir la observación o_{t+1} y marcar `done = True` cuando $t = T$.

4. **Reset.** En `reset()`, inicializar:

$$x_1 = x^{init}, \quad w_0 = w^{init}, \quad t = 1,$$

y devolver la observación inicial o_1 .

2.3 Etapa 3: Definición de agentes y arquitecturas (PPO y SAC)

Espacio de observación y acción. Configurar en `stable_baselines3`:

- Box continuo para el espacio de observación, con límites apropiados.
- Box continuo para el espacio de acción, con límites, por ejemplo, en $[-1, 1]$ y posterior proyección al simplex como se indicó.

PPO (on-policy, policy gradient).

- Usar PPO con política tipo `MlpPolicy`.
- Arquitectura sugerida: 2–3 capas densas intermedias con activaciones no lineales (ReLU o Tanh), tamaño moderado (p.ej., 64–128 neuronas) para evitar sobreparametrizar.
- Hiperparámetros a calibrar: tamaño de batch, longitud de rollouts, coeficiente de entropía, `clip_range`, tasa de aprendizaje, coeficiente de valor.

SAC (off-policy, actor–critic máximo-entropía).

- Usar SAC con política `MlpPolicy` y acción continua.
- Arquitecturas similares para actor y críticos (2–3 capas densas).
- Hiperparámetros clave: tasa de aprendizaje, `tau` para *target networks*, temperatura de entropía (fija o automática).

Capacidad de los agentes y error de generalización. El objetivo es minimizar el error de generalización (diferencia entre desempeño en entrenamiento y en test). Para ello:

1. **Control de capacidad.** Ajustar la profundidad y el ancho de las redes para que capturen patrones relevantes sin sobreajuste evidente.
2. **Regularización implícita.**
 - En PPO: controlar `clip_range` y tasa de aprendizaje para evitar updates agresivos.
 - En SAC: ajustar la temperatura de entropía para evitar políticas excesivamente deterministas durante el entrenamiento.
3. **Evaluación en validación.** Durante el entrenamiento, usar un *evaluation callback* que mida periódicamente:

$$\hat{J}_{val}(\theta) = \frac{1}{N_{ep}} \sum_{e=1}^{N_{ep}} (\text{retorno acumulado en episodios de validación}),$$

y seleccionar el modelo con mejor desempeño en validación.

4. **Walk-forward y múltiples semillas.** Repetir el entrenamiento con distintas semillas iniciales y, opcionalmente, distintos sub-períodos de entrenamiento para medir robustez y estabilidad.

2.4 Etapa 4: Diseño de pruebas de comparación

Se propone un esquema de comparación con las siguientes referencias:

1. Base determinista (GAMS, media-varianza con costos).

- Resolver el modelo media-varianza con costos de transacción en GAMS para ventanas móviles de longitud H (por ejemplo, 26–52 semanas) usando las estimaciones μ_t y Σ_t disponibles hasta el tiempo actual.
- En cada fecha t :
 - (a) Construir una ventana *rolling* $[t, t+H-1]$ con parámetros pronosticados.
 - (b) Resolver el problema determinista en esa ventana (maximización de media-varianza con costos).
 - (c) Aplicar sólo la primera decisión w_t^{GAMS} .
 - (d) Avanzar al siguiente periodo $t+1$ y repetir (esquema de *rolling horizon*).
- Evolucionar el capital x_t^{GAMS} con los retornos realizados y registrar la trayectoria.

2. Agentes DRL (PPO y SAC).

- Para cada agente entrenado (PPO y SAC), fijar los parámetros finales θ^* y evaluar en el periodo de test:

$$x_t^{PPO}, \quad x_t^{SAC}, \quad t \in test,$$

usando retornos realizados y el mismo esquema de costos.

3. Benchmarks adicionales.

- Portafolio buy-and-hold (por ejemplo, 50/50).
- Portafolio 50/50 con rebalanceo periódico fijo.

2.5 Etapa 5: Métricas de evaluación y comparación

Para comparar GAMS vs. PPO vs. SAC vs. benchmarks se propone:

- **Retorno acumulado:**

$$RetAcum = \frac{x_T}{x_1} - 1.$$

- **Volatilidad del portafolio:** desviación estándar de los retornos de portafolio r_t^{port} .
- **Medidas riesgo-retorno:** ratio de Sharpe, semivarianza, drawdowns máximos.
- **Rotación y costos:** promedio de $turn_t$ y costo acumulado de transacción.
- **Error de generalización:** diferencia entre métricas en train/validation y test para cada agente, y comparación del agente DRL contra la solución rolling de GAMS:

$$Regret_{GAMS}^{DRL} = RetAcum^{GAMS} - RetAcum^{DRL},$$

evaluado en el periodo de test.

2.6 Etapa 6: Síntesis

La metodología propuesta permite:

1. Formular el problema de portafolio con costos de transacción como un MDP bien definido.
2. Entrenar agentes DRL (PPO y SAC) que aprenden políticas π_θ o μ_θ a partir de datos históricos o simulados.
3. Controlar la capacidad de los agentes y el error de generalización mediante particiones temporales, callbacks de evaluación y experimentos con múltiples semillas.
4. Comparar de forma rigurosa el desempeño de los agentes DRL contra la solución determinista GAMS en un esquema de *rolling horizon*, y contra benchmarks simples, tanto en términos de retorno esperado como de riesgo y costos de transacción.